

单机实测 RTX 5070 12GB / i5-14600K / 32GB / Windows 10，结论不迁移到其他硬件

全表通用条件：同一张测试图 test-image.png、同一 prompt (temperature=0.0 / top_p=0.8 / max_tokens=500)、-c 8192 六组一致；1069 prompt tokens、230 输出 tokens；prompt tok/s 取服务端 timings.prompt_per_second (cache_prompt=false 全量重算)，decode tok/s 取 timings.predicted_per_second，首 token 取客户端 SSE 首个分片；显存为整卡 used，含桌面约 1331 MiB；每组跑完即卸模型再起下一组。

H1《12GB 显存本地部署对照表》| 数值出处: org\articles\R14-coder-bench.md (第 20–27、44–49、62–79 行)，未新增任何数字

组号	参数差异	mmproj 位置	prompt tok/s	decode tok/s	首token 冷 / 热•全量 / 缓存命中	显存 MiB (待机/峰值)	精度是否命中	条件脚注
单机实测 RTX 5070 12GB / i5-14600K / 32GB / Windows 10，结论不迁移到其他硬件								
G1 基线	-ngl 99 --no-mmproj-offload (FA 默认关、KV f16、-t 10)	CPU	80.07	117.33	12.97 s / 13.37 s / 0.030 s	6290 / 6297	4/4 字段 + 结论	[1][2][3][4][5]
G2 FA 开关	G1 + -fa on	CPU	78.40	116.71	未测 / 13.66 s / 0.032 s	6273 / 6297	4/4 字段 + 结论	[1][2][3][4][5]
G3 KV q8_0	G2 + -ctk q8_0 -ctv q8_0	CPU	83.92	113.57	未测 / 12.76 s / 0.031 s	6063 / 6088	4/4 字段 + 结论	[1][2][3][4][5]
G4 mmproj 上卡	-ngl 99 -fa on，去掉 --no-mmproj-offload	GPU	2322.94	116.71	0.586 s / 0.481 s / 0.031 s	8268 / 8369	4/4 字段 + 结论	[1][2][3][4][5]
G5 线程数 -t 12	G2 + -t 12 (默认实测 10)	CPU	87.55	117.93	未测 / 12.27 s / 0.054 s	6273 / 6296	4/4 字段 + 结论	[1][2][3][4][5]
G6 CPU 退化	同模型改从 ...\\Programs\\Ollama\\lib\\ollama 下启动 (-ngl 99 -fa on --no-mmproj-offload -t 10，-ngl 99 静默忽略)	CPU (未能上卡)	39.02	12.70	27.42 s (全量，无 GPU；原文未区分冷/热) 缓存命中：未测	1329→1332 / 峰值 1342	4/4 字段 + 结论 (慢但算对)	[1][2][3][4][6]

1. 本次请求 (每行同口径)：1069 prompt tokens、230 输出 tokens、-c 8192；prompt tok/s 为 cache_prompt=false 全量重算读数。
2. 显存口径：整卡 nvidia-smi used，含桌面约 1331 MiB。「待机」= 模型加载完成后、发起请求前；「峰值」= 本次请求期间最大值。
3. 首 token 三口径分开报、不混用：「冷」= 本次 server 进程的第一次多模式调用；「热•全量」= 同进程后续调用且 cache_prompt=false 全量重算；「缓存命中」= 同进程、相同 prompt、KV 前缀复用（服务端只算 1 个 token）。原文未给 G2/G3/G5 的冷启动读数，故写「未测」。
4. 精度判据：make_test_image.py 真值逐字比对——gps_lat 128,430/0.42%/17、gps_lon 128,430/0.38%/9、road_name 128,430/6.71%/132、speed_limit 96,215/12.05%/48 四项全中；结论句原样输出 (含「6.71%」「P2」「7 日内回补」)。六组回答逐字一致——FA、KV 量化、mmproj 位置乃至 CPU 退化都没有改变输出。
5. decode 为两次读数，本表取首跑：G2 116.71 (次跑 115.87)、G3 113.57 (次跑 111.81)、G4 116.71 (次跑 118.07)、G5 117.93 (次跑 115.19)；G1 117.33、G6 12.70 为单次读数。
6. 单位归一说明 (不改数值)：「缓存命中」秒数在原文中写作 0.030 s (G1)、0.032 (G2)、0.031 (G3)、0.031 (G4)、0.054 (G5)，本表统一补单位 s，数值逐字未改。
7. G6 判据：启动目录同级没有 ggml-cuda.dll / cublas64_13.dll (只在子目录 cuda_v13\ 下)；进程正常、/health 正常 ok、日志无 CUDA offload 行也无报错，GPU 占用全程恒 1329–1342 MiB。此场景下 mmproj 同样无法上卡。

一句话结论：同一张 12GB 显卡、同一张图，把 mmproj 放回 GPU：prompt 80.07 → 2322.94 tok/s、热•全量首 token 13.37 s → 0.481 s、冷启动 12.97 s → 0.586 s，代价是显存 6273 → 8268 MiB (峰值 8369)，全程无 OOM。G6 提醒：进程正常不等于 GPU 在跑——显存只占 1.3 GB 就是模型在 CPU 上 (decode 12.70 vs 117.33，慢 9.2 倍)。

本文所有性能数字均为单机实测：RTX 5070 12GB (12227 MiB) / i5-14600K / 32GB 内存 / Windows 10，同一张测试图与同一 prompt；结论不迁移到其他硬件，你的读数以自己机器为准。

可编辑内容源: H1-对照表.md | 本页 1 页 (A4 横向, 可直接打印) | 原始日志: D:\ollama\bench-r14\server-G*.log、result-G*.json | 本页无外链、无第三方素材。